МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«Национальный исследовательский университет ИТМО»

ФАКУЛЬТЕТ ПРОГРАММНОЙ ИНЖЕНЕРИИ И
КОМПЬЮТЕРНОЙ ТЕХНИКИ

ЛАБОРАТОРНАЯ РАБОТА №4

по дисциплине

«ИНФОРМАТИКА»

Исследование протоколов,
форматов обмена информацией и языков разметки документов

Вариант №409858 % 36 + 8 = 22 + 8 = 30

Выполнил:
Студент группы P3107
Чусовлянов Максим Сергеевич
Проверил:
Балакшин Павел Валерьевич
кандидат технических наук, доцент факультета ПИиКТ

Санкт-Петербург, 2023

Содержание

Задание

1. Определить номер варианта как остаток деления на 36 последних двух цифр своего идентификационного номера в ISU. В случае, если в данный день недели нет занятий, то увеличить номер варианта на восемь.
2. Изучить форму Бэкуса-Наура.
3. Изучить основные принципы организации формальных грамматик.
4. Изучить особенности языков разметки/форматов JSON, YAML, XML.
5. Понять устройство страницы с расписанием на примере расписания лектора: https://itmo.ru/ru/schedule/3/125598/raspisanie_zanyatiy.htm
6. Исходя из структуры расписания конкретного дня, сформировать файл с расписанием в формате, указанном в задании в качестве исходного. При этом необходимо, чтобы в выбранном дне было не менее двух занятий (можно использовать своё персональное). В случае, если в данный день недели нет таких занятий, то увеличить номер варианта ещё на восемь.
7. **Обязательное задание** (позволяет набрать до 45 процентов от максимального числа баллов БаРС за данную лабораторную): написать программу на языке Python 3.x, которая бы осуществляла парсинг и конвертацию исходного файла в новый путём простой замены метасимволов исходного формата на метасимволы результирующего формата. Нельзя использовать готовые библиотеки, в том числе регулярные выражения в Python и библиотеки для загрузки XML-файлов.
8. **Дополнительное задание №1** (позволяет набрать +10 процентов от максимального числа баллов БаРС за данную лабораторную).

   a) Найти готовые библиотеки, осуществляющие аналогичный парсинг и конвертацию файлов.

   b) Переписать исходный код, применив найденные библиотеки Регулярные выражения также нельзя использовать.

   c) Сравнить полученные результаты и объяснить их сходство/различие. Объяснение должно быть отражено в отчёте.

9. **Дополнительное задание №2** (позволяет набрать +10 процентов от максимального числа баллов БаРС за данную лабораторную).

   a) Переписать исходный код, добавив в него использование регулярных выражений.

   b) Сравнить полученные результаты и объяснить их сходство/различие. Объяснение должно быть отражено в отчёте.

10. **Дополнительное задание №3** (позволяет набрать +25 процентов от максимального числа баллов БаРС за данную лабораторную).

    a) Переписать исходный код таким образом, чтобы для решения задачи использовались формальные грамматики. То есть ваш код должен уметь осуществлять парсинг и конвертацию любых данных, представленных в исходном формате, в данные, представленные в результирующем формате: как с готовыми библиотеками и дополнительного задания №1.

    b) Проверку осуществить как минимум для расписания с двумя учебными днями по два занятия в каждом.

    c) Сравнить полученные результаты и объяснить их сходство/различие. Объяснение должно быть отражено в отчёте.

11. **Дополнительное задание №4** (позволяет набрать +5 процентов от максимального числа баллов БаРС за данную лабораторную).

    a) Используя свою исходную программу из обязательного задания и программы из дополнительных заданий, сравнить стократное время выполнения парсинга + конвертации в цикле.

    b) Проанализировать полученные результаты и объяснить их сходство/различие. Объяснение должно быть отражено в отчёте.

12. **Дополнительное задание №5** (позволяет набрать +5 процентов от максимального числа баллов БаРС за данную лабораторную).

    a) Переписать исходную программу, чтобы она осуществляла парсинг и конвертацию исходного файла в любой другой формат (кроме JSON, YAML, XML, HTML): PROTOBUF, TSV, CSV, WML и т.п.

    b) Проанализировать полученные результаты, объяснить особенности использования формата. Объяснение должно быть отражено в отчёте.

Основные этапы вычисления

Сб	08:20-09:50 3, 7, 9, 11, 13, 15	PRLCOMP 1	1324 АУД. Кронверкский пр., д.49, лит.А	ПАРАЛЛЕЛЬНЫЕ ВЫЧИСЛЕНИЯ / PARALLEL COMPUTING (ЛЕК)	Очно - дистанционный
	10:00-11:30 3, 7	PRLCOMP 1	1324 АУД. Кронверкский пр., д.49, лит.А	ПАРАЛЛЕЛЬНЫЕ ВЫЧИСЛЕНИЯ / PARALLEL COMPUTING (ЛЕК)	Очно - дистанционный
	10:00-11:30 9, 11, 13	PRLCOMP 1.1	1324 АУД. Кронверкский пр., д.49, лит.А	ПАРАЛЛЕЛЬНЫЕ ВЫЧИСЛЕНИЯ / PARALLEL COMPUTING (ЛАБ)	Очно - дистанционный
	10:00-11:30 2, 4, 6, 8, 12, 14, 16, 18	ИНФОРМ 3.4	2112 АУД. Кронверкский пр., д.49, лит.А	ИНФОРМАТИКА (ЛАБ)	Очно - дистанционный
	11:40-13:10 2, 4, 6, 8, 12, 14, 16, 18	ИНФОРМ 3.4	2112 АУД. Кронверкский пр., д.49, лит.А	ИНФОРМАТИКА (ЛАБ)	Очно - дистанционный
	13:30-15:00 3, 7, 9, 11, 13	PRLCOMP 1.1	1324 АУД. Кронверкский пр., д.49, лит.А	ПАРАЛЛЕЛЬНЫЕ ВЫЧИСЛЕНИЯ / PARALLEL COMPUTING (ЛАБ)	Очно - дистанционный
	13:30-15:00 2, 4, 6, 8, 12, 14, 16, 18	ИНФОРМ 3.5	2112 АУД. Кронверкский пр., д.49, лит.А	ИНФОРМАТИКА (ЛАБ)	Очно - дистанционный
	15:20-16:50 2, 4, 6, 8, 12, 14, 16, 18	ИНФОРМ 3.5	2112 АУД. Кронверкский пр., д.49, лит.А	ИНФОРМАТИКА (ЛАБ)	Очно - дистанционный

Рисунок 1.1 (расписание лектора)

Пример файла с расписанием в формате JSON:


```
{
  "current_day": 6,
  "current_week": 11,
  "current_time": "12:05",
  "schedule": [
        {
              "id": 1337,
              "title": "Параллельные вычисления / Parallel Computing",
              "group": "PRLCOMP 1",
              "teacher": {
                    "id": 125598,
                    "name": "Балакшин Павел Валерьевич"
              },
              "class_type": {
                    "id": 0,
                    "name": "Лекция”
              },
              "class_format": {
                    "id": 2,
                    "name": "Очно - дистанционный"
              },
              "date": {
                    "day": 6,
                    "weeks": [3, 7, 9, 11, 13, 15]
              },
              "time": {
                    "class_number": 1,
                    "from": "08:20",
                    "to": "09:50"
              },
              "classroom": {
```

```
                "id": 1324,
                "name": "1324 ауд."
            },
            "campus": {
                "id": 0,
                "adress": "Кронверкский пр., д.49, лит.А"
            }
        },
        …
]}
```


Обязательное задание:

Исходный файл json:
https://github.com/Vaneshik/VT-Labs/blob/main/informatics/lab4/data/in.json

Исходный код:
https://github.com/Vaneshik/VT-Labs/tree/main/informatics/lab4/main_task

Результат:
https://github.com/Vaneshik/VT-Labs/blob/main/informatics/lab4/data/out.xml

Дополнительное задание 1:

Исходный код:
https://github.com/Vaneshik/VT-Labs/blob/main/informatics/lab4/additional_task1/main.py

Результат:
https://github.com/Vaneshik/VT-Labs/blob/main/informatics/lab4/data/out1.xml

Готовые библиотеки: стандартная библиотека Python json для парсинга JSON и dicttoxml для дампа словаря в файл xml.

Файл результата не отличается от результата обязательного задания, кроме как тем, что при использовании библиотеки элементы списков заключены в парный тег “<item>”, когда при использовании самописной реализации используется “<[KEY]_elem>”. Код программы стал значительно проще – теперь он состоит из одной функции и чтения файлов

Дополнительное задание 2:

Исходный код:
https://github.com/Vaneshik/VT-Labs/tree/main/informatics/lab4/additional_task2

Результат:
https://github.com/Vaneshik/VT-Labs/blob/main/informatics/lab4/data/out1.xml

Файл результата не отличается от результата обязательного задания. Единственное изменение в коде программы - парсинг чисел и строк заменены на регулярные выражения вместо циклов.

Дополнительное задание 3:

Исходный код:
https://github.com/Vaneshik/VT-Labs/blob/main/informatics/lab4/additional_task3/main.py

Результат:
https://github.com/Vaneshik/VT-Labs/blob/main/informatics/lab4/data/out3.xml

Мной изначально был написан код с использованием формальных грамматик. Поэтому я смог импортировать нужные мне функции из обязательного задания. Парсер умеет конвертировать JSON в любом формате, что было протестировано мной при помощи JSON Parsing Test Suite.

Дополнительное задание 4:

Исходный код:
https://github.com/Vaneshik/VT-Labs/tree/main/informatics/lab4/additional_task4

1) Время работы программы для обязательного задания:
0.9949188232421875 секунды;

2) Время работы программы для доп. задания №1 (программа использует библиотеку dicttoxml):
1.314805269241333 секунды;

3) Время работы программы для доп. задания №2 (программа использует библиотеку re):
1.7888438701629639 секунды.

Данные результаты удивили меня.
Скорее всего узким горлышком доп. задания 1 является библиотека dicttoxml. Изучив ее исходный код, мы можем понять что там существует множество дополнительных проверок (например CDATA sections), для того чтобы максимально точно соответствовать формату xml и не допускать ошибок. В то время как код из обязательного задания просто “оборачивает” значение в тег ключа с форматированными пробелами.
Регулярные выражение работают дольше, так как не используется компиляция (re.compile) регулярных выражений и проверка регуляркой идет дольше чем итерация по строке (за O(n)).

Дополнительное задание 5:

Исходный код:
https://github.com/Vaneshik/VT-Labs/blob/main/informatics/lab4/additional_task5/main.py

Результат:
https://github.com/Vaneshik/VT-Labs/blob/main/informatics/lab4/data/out5.tsv

TSV (tab separated values — значения, разделённые табуляцией) — текстовый формат для представления таблиц баз данных. Каждая запись в таблице — это строка текстового файла. Каждое поле записи отделяется от других с помощью символа табуляции, точнее горизонтальной табуляции.

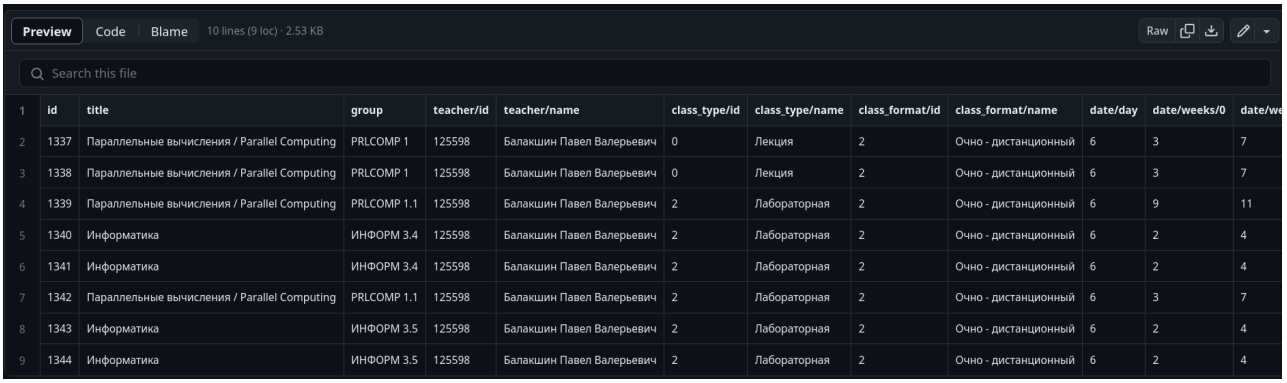

Preview | Code | Blame | 10 lines (9 loc) · 2.53 KB | Raw

Search this file

	id	title	group	teacher/id	teacher/name	class_type/id	class_type/name	class_format/id	class_format/name	date/day	date/weeks/0	date/we
2	1337	Параллельные вычисления / Parallel Computing	PRLCOMP 1	125598	Балакшин Павел Валерьевич	0	Лекция	2	Очно - дистанционный	6	3	7
3	1338	Параллельные вычисления / Parallel Computing	PRLCOMP 1	125598	Балакшин Павел Валерьевич	0	Лекция	2	Очно - дистанционный	6	3	7
4	1339	Параллельные вычисления / Parallel Computing	PRLCOMP 1.1	125598	Балакшин Павел Валерьевич	2	Лабораторная	2	Очно - дистанционный	6	9	11
5	1340	Информатика	ИНФОРМ 3.4	125598	Балакшин Павел Валерьевич	2	Лабораторная	2	Очно - дистанционный	6	2	4
6	1341	Информатика	ИНФОРМ 3.4	125598	Балакшин Павел Валерьевич	2	Лабораторная	2	Очно - дистанционный	6	2	4
7	1342	Параллельные вычисления / Parallel Computing	PRLCOMP 1.1	125598	Балакшин Павел Валерьевич	2	Лабораторная	2	Очно - дистанционный	6	3	7
8	1343	Информатика	ИНФОРМ 3.5	125598	Балакшин Павел Валерьевич	2	Лабораторная	2	Очно - дистанционный	6	2	4
9	1344	Информатика	ИНФОРМ 3.5	125598	Балакшин Павел Валерьевич	2	Лабораторная	2	Очно - дистанционный	6	2	4

Рисунок 1.2 (пример полученной таблицы после конвертации)

Заключение

В ходе проделанной лабораторной работы, я познакомился с разными форматами файлов. Узнал о существовании формальных грамматик и БНФ. Написал парсеры, которые конвертируют json-файл в формат xml и tsv. Получил удовольствие от 5 часового кодинга рекурсивного парсера на формальных грамматиках.

Список литературы

1. [Электронный ресурс]: Википедия. Свободная энциклопедия. – Режим доступа: https://ru.wikipedia.org/wiki/JSON
2. Грошев А.С. Г89 Информатика: Учебник для вузов / А.С. Грошев. – Архангельск, Арханг. гос. техн. ун-т, 2010. - 470с. - Режим доступа: http://arm.sies.uz/wp-content/uploads/2020/11/16-%D0%98%D0%BD%D1%84%D0%BE%D1%80%D0%BC%D0%B0%D1%82%D0%B8%D0%BA%D0%B0-2010-%D0%B4%D0%B0%D1%80%D1%81%D0%BB%D0%B8%D0%BA-%D0%93%D1%80%D0%BE%D1%88%D0%B5%D0%B2-%D0%90.%D0%A1.pdf